



浙江大学
ZHEJIANG UNIVERSITY

自然语言处理导论 实验报告

基于 GRPO 与可验证奖励的 24 点游戏求解

成员 黄晗 刘泽晖 王子朔 赵一帆 叶顺凡

学院 计算机科学与技术学院

专业 计算机科学与技术

指导老师 汤斯亮

2026 年 6 月 14 日

目录

1	引言与贡献	4
2	任务定义与挑战分析	4
2.1	任务定义	4
2.2	主要挑战	5
3	问题建模与创新设计	6
3.1	Target-aware 统一建模	6
3.2	Verifier-based RLVR	6
3.3	不可解样本的 Hallucination 建模	7
3.4	Verifier-based Test-time Compute	7
4	方法	7
4.1	Prompt 与输出格式	7
4.2	安全表达式验证器	7
4.3	奖励函数	8
4.4	SFT Warm-up	8
4.5	GRPO 训练	9
4.6	Best-of-N Verifier 解码	9
5	实验与结果分析	10
5.1	实验设置	10
5.2	主结果: Base vs SFT vs SFT+GRPO	11
5.3	Verifier-based Test-time Compute	12
5.4	不可解样本 Hallucination 分析	14
5.5	GRPO 训练稳定性与超参对照	14
5.6	训练曲线	16
5.7	错误类型分析	17
5.8	Hard Split 难度分析	18
5.9	Countdown 加分项	19
6	结论	20
6.1	局限性	20
6.2	总结	21
7	参考文献	21

8 附录：复现命令与结果路径 22

8.1 主线实验 22

8.2 Best-of-N Sweep 22

8.3 Countdown 加分项 23

8.4 关键结果路径 23

基于 GRPO 与可验证奖励的 24 点游戏求解

摘要

本次实验我们面向 24 点游戏构建了一个可验证奖励强化学习 (RLVR) 实验系统。给定 4 个 1-13 之间的整数，模型需要按照 R1 风格输出一个只使用四则运算和括号的表达式，并且每个输入数字恰好使用一次、结果等于 24。实验以 Qwen2.5-1.5B-Instruct 为主线，采用 SFT warm-up 建立基本表达式生成能力，再使用 GRPO 进行可验证奖励强化学习。

最终结果显示，SFT+GRPO + verifier best-of-16 在 Official OOD split 上达到 65.5%，在 Tree of Thoughts hard split 900-1000 上达到 49.0%，不可解样本幻觉率为 0.0%。除主任务外，项目还将验证器、prompt 与 reward 扩展为 target-aware 形式，在 Countdown 任意目标数任务上完成加分项验证。

1 引言与贡献

24 点游戏是一个典型的小规模组合推理任务。它既要求模型理解自然语言 prompt，又要求模型完成离散搜索、算术计算和格式约束。更重要的是，答案是否正确可以由程序严格验证，因此它非常适合作为 RLVR 场景：不需要人工偏好标注，也不需要训练额外奖励模型。

相关工作为本项目提供了三条技术脉络：DeepSeekMath 提出 GRPO，以组内相对奖励降低策略优化成本 [1]；DeepSeek-R1 与 Logic-RL 展示了规则奖励强化学习对推理能力的激励作用 [2,7]；Tree of Thoughts 在 24 点任务上验证了多路径搜索的价值 [5]，TinyZero 则将类似思想用于 Countdown 等可验证算术任务 [6]。本项目在此基础上采用更轻量的 SFT+GRPO 与符号验证器组合，并参考 TRL 和 Open-R1 的开放训练工具链 [9-10]。

本次实验我们的主要工作和亮点如下：

1. 构建了 Qwen2.5-1.5B-Instruct 的完整训练闭环：base evaluation、SFT warm-up、SFT 后 GRPO continuation。
2. 将 24 点任务统一建模为 $(\text{numbers}, \text{target}) \rightarrow \text{expression}$ ，使同一套 verifier/reward 可迁移到 Countdown 任意目标数任务。
3. 显式引入不可解样本评估，将模型“会不会解题”和“会不会拒绝乱编”同时纳入评价。
4. 使用 verifier-based test-time compute，将模型输出建模为候选表达式生成，并用程序验证器筛选正确解。
5. 对结果进行错误类型、hard split 难度和 GRPO 超参稳定性分析，避免只报告单一准确率。

2 任务定义与挑战分析

2.1 任务定义

24 点主任务输入为 4 个整数：

```
numbers = [a, b, c, d],  a,b,c,d in {1, ..., 13}  
target = 24
```

模型输出必须满足：

```
<think>reasoning process</think>
```

```
<answer>expression</answer>
```

其中 `expression` 只能包含输入数字、四则运算符 `+` `-` `*` `/` 与括号。验证器检查三类约束：

1. 数字使用约束：每个输入数字必须且只能使用一次。
2. 语法安全约束：表达式只允许四则运算和括号。
3. 目标值约束：表达式计算结果与 `target` 的误差不超过 $1e-6$ 。

对于不可解输入，模型应输出 `NO_SOLUTION`，而不是强行编造表达式。

2.2 主要挑战

组合搜索空间大。 24 点求解涉及数字排列、运算符选择和括号结构组合。模型需要隐式完成离散搜索，而不是简单记忆答案。

奖励稀疏。 只有完整表达式通过验证器时才获得准确率奖励，部分正确的中间步骤通常无法直接得分。

格式与语义双重约束。 模型既要遵守 DeepSeek-R1 类 `<think>/<answer>` 输出模板 [2]，又要保证 `<answer>` 内表达式真实可执行、可验证。

不可解样本存在幻觉风险。 大语言模型倾向于生成看似合理的答案。对不可解样本，如果没有单独建模，模型可能始终输出一个错误表达式。

强化学习训练不稳定。 GRPO 可以提升候选池质量，但也可能扰动 SFT 后的拒答行为，导致 greedy 下 hallucination 上升。

3 问题建模与创新设计




图 1: 方法总图

3.1 Target-aware 统一建模

我们没有将验证器写死为 24，而是将任务统一表示为：

`(numbers, target) -> expression`

24 点是 `target=24` 的特例。Countdown 任务则使用每条样本自己的 `target`，因此 `prompt`、`reward`、`verifier` 和 `evaluation` 均可复用。这使系统从固定 24 点求解器扩展为通用的小规模算术目标构造器。

3.2 Verifier-based RLVR

奖励不依赖人工标注或奖励模型，而由程序验证器直接给出。验证器基于 AST 安全解析表达式，过滤非法语法、非法数字使用和错误结果。这样的奖励完全可复现，也避免了自然语言奖励模型在算术任务上的不稳定判断。

3.3 不可解样本的 Hallucination 建模

我们将不可解样本作为独立 split。若模型在不可解题中输出错误表达式，则记为 hallucination；若输出 NO_SOLUTION 或等价拒答，则视为正确拒答。该设计把任务从“只求解可解题”扩展为“求解与可解性判断”的联合问题。

3.4 Verifier-based Test-time Compute

单次 greedy 输出无法充分反映模型候选池中的潜在能力。为此，我们在测试时采样多个候选，并用验证器选择第一个正确表达式。该过程等价于：

```
language model -> candidate pool -> verifier selection
```

这与 Tree of Thoughts[5] 和 TinyZero[6] 的思想一致，但实现更轻量：不需要人工打分，也不需要额外搜索模型。

4 方法

4.1 Prompt 与输出格式

训练和评估均使用 R1 风格模板：

```
<think>
brief reasoning process
</think>
<answer>
(1+2+3)*4
</answer>
```

评估时只验证 <answer> 中的表达式。这样既保留 reasoning 格式，又避免将自然语言推理文本纳入算术验证。

4.2 安全表达式验证器

验证器执行以下步骤：

1. 从 completion 中抽取 <answer>。
2. 若答案为 NO_SOLUTION，进入不可解样本拒答判断。

3. 使用 AST 解析表达式，拒绝函数调用、变量、列表等非四则运算语法。
4. 统计表达式中出现的数字，与输入 multiset 精确匹配。
5. 计算表达式值，判断是否满足 $\text{abs}(\text{value} - \text{target}) \leq 1e-6$ 。

4.3 奖励函数

GRPO 训练使用格式奖励和准确率奖励的加权组合：

$$R = w_f R_{\text{format}} + w_a R_{\text{accuracy}}$$




图 2: Verifier/reward 构造

其中 R_{format} 检查 `<think>` 与 `<answer>` 标签是否完整， R_{accuracy} 检查答案是否通过验证器。对于不可解样本，正确拒答获得正向奖励，乱编表达式受到惩罚。

4.4 SFT Warm-up

直接对基础模型做 GRPO 容易学到格式捷径，例如只输出固定标签或固定数字。为缓解稀疏奖励问题，我们先使用可验证表达式进行 SFT warm-up，使模型具备：

1. 稳定输出 R1 格式的能力；
2. 生成合法表达式的基本能力；
3. 在不可解样本上输出拒答的能力。

SFT 后再进行 GRPO，强化学习主要用于改善候选表达式质量，而不是从零学习格式。

4.5 GRPO 训练

GRPO 对同一个 prompt 采样一组候选，根据组内相对奖励计算优势 [1]。设同组奖励为 $r_1, \dots, r_G$ ，则第 i 个候选的优势为：

$$A_i = (r_i - \text{mean}(r)) / (\text{std}(r) + \text{epsilon})$$

训练流程如下：

```
for prompt in training_prompts:
    candidates = sample(model, prompt, G)
    rewards = [verifier_reward(c) for c in candidates]
    advantages = normalize_within_group(rewards)
    update_policy_with_GRPO(candidates, advantages)
```

本次实验主线使用 GRPO_SAMPLES=300、GRPO_GENERATIONS=8，并补充低学习率对照以分析训练稳定性。

4.6 Best-of-N Verifier 解码

评估阶段的 best-of-N 不改变模型参数，只增加测试时采样候选数：

```
for problem in test_set:
    candidates = sample(model, problem, N)
    for candidate in candidates:
        if verifier(candidate) == correct:
            return candidate
    if problem is unsolvable and any candidate is NO_SOLUTION:
        return NO_SOLUTION
    return failed
```




图 3: Best-of-N 机制图

该方法将语言模型作为候选生成器，将精确验证交给程序完成。

5 实验与结果分析

5.1 实验设置

5.1.1 数据集与评估 Split

Split	来源	用途	规模
ID	nlile/24-game[11]	分布内可解题评估	200
Official OOD	game-of-24[12]	官方分布外泛化评估	200
ToT hard 900-1000	game-of-24 indices 900:1000[5,12]	Tree of Thoughts 常用难题	100
Unsolvable	nlile/24-game 不可解样本	幻觉检测	100
Countdown	Countdown-Tasks-3to4[13]	任意目标数加分项	200

Official OOD 和 ToT hard 来自同一个 official game-of-24 benchmark。ToT hard 是其中 indices 900-1000 的 100 道困难题，平均官方 solved rate 更低、平均 rank 更高。

5.1.2 训练配置

项目	设置
Backbone	Qwen2.5-1.5B-Instruct[3-4]
参数高效微调	LoRA[8]
主线流程	base eval → SFT warm-up → GRPO continuation
SFT 学习率	8e-5
GRPO 主线学习率	8e-7
GRPO prompt 数	300
GRPO num generations	8
解码方式	greedy, best-of-1/4/8/16

训练实现使用 Hugging Face TRL 的 GRPOTrainer, 并参考 Open-R1 的开放 SFT/-GRPO 工作流 [9-10]。

5.1.3 评价指标

指标	含义
Solve rate	表达式合法、数字使用正确且结果等于 target 的比例
Format rate	输出是否满足 <think>...</think><answer>...</answer>
Hallucination rate	不可解样本上仍输出错误表达式的比例
Error counts	format_error、number_mismatch、wrong_value、invalid_expression 等错误计数
Difficulty	official benchmark 的 solved_rate 与 rank 聚合

5.2 主结果：Base vs SFT vs SFT+GRPO

模型阶段	解码	ID	Official OOD	ToT hard	不可解幻觉	Format
Base	greedy	0.0%	2.0%	1.0%	100.0%	49.0%
Base	best-of-8	1.5%	3.0%	1.0%	80.0%	42.5%
SFT	greedy	4.0%	11.0%	10.0%	4.0%	100.0%
SFT	best-of-8	22.0%	31.0%	13.0%	0.0%	100.0%
SFT+GRPO	greedy	7.5%	14.5%	12.0%	34.0%	100.0%
SFT+GRPO	best-of-8	27.5%	43.5%	32.0%	1.0%	100.0%
SFT+GRPO	best-of-16	44.0%	65.5%	49.0%	0.0%	100.0%




图 4: 主结果柱状图

基础模型几乎无法稳定完成任务，且不可解样本幻觉率达到 100%。SFT 后 format rate 达到 100%，不可解幻觉显著下降，说明 warm-up 解决了格式和拒答基础能力。图中分别在 greedy 与 best-of-8 两种一致解码设置下比较三个训练阶段：GRPO 在 greedy 下提升有限，但在 best-of-8 下显著提升 OOD 和 hard split，说明它主要改善候选池质量。

5.3 Verifier-based Test-time Compute

解码	ID	Official OOD	ToT hard	不可解幻觉
greedy	7.5%	14.5%	12.0%	34.0%
best-of-1	4.5%	10.5%	2.0%	50.0%
best-of-4	15.0%	25.5%	14.0%	7.0%
best-of-8	27.5%	43.5%	32.0%	1.0%
best-of-16	44.0%	65.5%	49.0%	0.0%




图 5: Best-of-N 曲线




图 6: Best-of-N 定性案例

以输入 $[2, 3, 6, 10]$ 为例, greedy 和 best-of-8 记录的候选均因 `wrong_value` 未通过验证, 而 best-of-16 生成了合法表达式 $(10-3*2)*6=24$ 。该案例直观说明: 增加候选预算并不改变模型参数, 而是提高正确表达式进入候选池的概率, 再由符号验证器完成可靠筛选。

best-of-N 是我们本次实验最明显的增益来源。对 SFT+GRPO, Official OOD 从 best-of-1 的 10.5% 提升到 best-of-16 的 65.5%, ToT hard 从 2.0% 提升到 49.0%。这说明模

型单次输出仍不稳定，但候选池中已经包含大量可由 verifier 筛出的正确表达式。

5.4 不可解样本 Hallucination 分析




图 7: 不可解幻觉率

不可解样本用于检查模型是否会强行编造答案。Base 在 best-of-1 到 best-of-16 下幻觉率仍高达 96.0% 到 64.0%。SFT 显著改善拒答能力，best-of-8 后幻觉率降为 0.0%。SFT+GRPO 的 greedy 幻觉率升至 34.0%，说明 RL 更新会扰动拒答行为；但 verifier best-of-16 最终将幻觉率降到 0.0%。

5.5 GRPO 训练稳定性与超参对照

GRPO 配置	Greedy OOD	Greedy hard	Greedy 幻 觉	Best-of-8 OOD	Best-of-8 hard	Best-of-8 幻觉
8e-7/s300/g8	14.5%	12.0%	34.0%	43.5%	32.0%	1.0%
3e-7/s300/g8	13.0%	11.0%	17.0%	39.0%	25.0%	0.0%
3e-7/s600/g8	15.0%	11.0%	25.0%	41.5%	31.0%	2.0%




图 8: GRPO 超参对照

低学习率能缓解 greedy 下的不可解幻觉，其中 $3e-7/s300$ 将 greedy 幻觉率从 34.0% 降至 17.0%。但主线 $8e-7/s300/g8$ 在 best-of-8 的 OOD 与 ToT hard 上仍最强。因此最终采用主线配置作为主要结果，并将低学习率实验作为训练稳定性分析。

5.6 训练曲线




图 9: SFT loss




图 10: GRPO reward




图 11: GRPO solved per group

SFT loss 持续下降, 说明 warm-up 阶段稳定学习了输出格式和表达式模式。GRPO 的 reward 与 solved per group 存在波动, 符合强化学习训练不稳定的预期。主线 GRPO 最后 50 step 的平均 reward 为 0.0412, 平均 solved per group 为 0.66, 说明训练后期候选池中正确表达式比例有所增加。

5.7 错误类型分析

以最终 SFT+GRPO + best-of-16 为例, 主要错误如下:

Split	主要错误
ID	wrong_value=74, refusal_or_no_answer=38
Official OOD	wrong_value=38, refusal_or_no_answer=31
ToT hard	wrong_value=38, refusal_or_no_answer=12, invalid_expression=1
Unsolvable	refused=100




图 12: 错误类型堆叠图

SFT 后格式错误基本消失,最终配置的失败样本主要由 `wrong_value` 与 `refusal_or_no_answer` 构成,其中 ToT hard 的失败样本中约 75% 为 `wrong_value`。这说明瓶颈已经从“格式学习”转向“算术搜索与组合推理”。在不可解 split 上,最终配置 100 个样本全部拒答,说明 verifier-based selection 能有效抑制幻觉。

5.8 Hard Split 难度分析

Split	样本数	官方平均 solved		SFT+GRPO	
		rate	平均 rank	best-of-16	
Official	200	96.98%	100.5	65.5%	
OOD					
ToT hard	100	85.88%	950.5	49.0%	
900-1000					




图 13: Hard split 难度分析

ToT hard 来自 official benchmark 的 indices 900-1000，平均 rank 明显更高，官方 solved rate 更低，因此比普通 OOD 更困难。模型在 hard split 上仍达到 49.0%，说明 verifier best-of-N 不只提升简单题，也能提升困难组合题表现。

5.9 Countdown 加分项

Countdown 任务将输入扩展为 3-4 个数字和任意 target，用于验证 target-aware 框架是否可迁移。

模型阶段	解码	Countdown solve	Format
SFT	greedy	10.5%	100.0%
SFT	best-of-8	42.0%	100.0%
SFT+GRPO	greedy	11.0%	100.0%
SFT+GRPO	best-of-8	40.5%	100.0%




图 14: Countdown 结果

Countdown 结果证明同一套 prompt、target-aware verifier 和 reward 可以迁移到任意目标数构造任务。best-of-8 相比 greedy 提升明显，但小规模 Countdown GRPO 未超过 SFT best-of-8，因此该部分更适合作为框架迁移验证，而不是声称 GRPO 在 Countdown 上带来显著增益。

6 结论

6.1 局限性

1. **Greedy 成功率仍低。**最终模型 greedy OOD 只有 14.5%，说明模型尚未稳定内化完整算术搜索策略。
2. **Best-of-N 带来额外推理成本。**best-of-16 显著提升性能，但每题需要采样更多候选。
3. **GRPO 会扰动拒答能力。**主线 GRPO greedy hallucination 从 SFT 的 4.0% 升至 34.0%，需要 verifier 或更保守超参控制。
4. **Countdown GRPO 增益有限。**Countdown 上 SFT best-of-8 为 42.0%，SFT+GRPO best-of-8 为 40.5%，说明任意目标任务仍需要更充分训练。
5. **训练规模较小。**主线 GRPO 只使用 300 prompts，结果更适合作为小规模 RLVR 验证，而非性能上限。

6.2 总结

本次实验我们完成了基于 Qwen2.5-1.5B-Instruct 的 24 点游戏 RLVR 实验。SFT warm-up 解决了基础模型格式不稳和不可解幻觉问题，GRPO 进一步提升了候选池质量，而 verifier-based best-of-N 将 OOD 和 hard split 表现显著放大。最终 SFT+GRPO + best-of-16 在 Official OOD 上达到 65.5%，在 ToT hard 上达到 49.0%，不可解幻觉率为 0.0%。

从建模角度看，项目不只是复现 GRPO，而是围绕 24 点任务补充了 target-aware 扩展、不可解幻觉评估、test-time verifier selection、错误类型诊断和 hard split 难度分析。这些设计使实验结果更可解释，也更适合作为 RLVR 在小规模可验证推理任务上的完整案例。

7 参考文献

1. Shao Z, Wang P, Zhu Q, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models[EB/OL]. arXiv:2402.03300, 2024. <https://arxiv.org/abs/2402.03300>.
2. DeepSeek-AI, Guo D, Yang D, et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[EB/OL]. arXiv:2501.12948, 2025. <https://arxiv.org/abs/2501.12948>.
3. Yang A, Yang B, Zhang B, et al. Qwen2.5 Technical Report[EB/OL]. arXiv:2412.15115, 2024. <https://arxiv.org/abs/2412.15115>.
4. Qwen Team. Qwen2.5-1.5B-Instruct Model Card[EB/OL]. Hugging Face, 2024. <https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>.
5. Yao S, Yu D, Zhao J, et al. Tree of Thoughts: Deliberate Problem Solving with Large Language Models[C]//Advances in Neural Information Processing Systems. 2023. <https://arxiv.org/abs/2305.10601>.
6. Pan J, et al. TinyZero: Minimal Reproduction of DeepSeek R1-Zero[EB/OL]. GitHub, 2025. <https://github.com/Jiayi-Pan/TinyZero>.
7. Xie T, Gao Z, Ren Q, et al. Logic-RL: Unleashing LLM Reasoning with Rule-Based Reinforcement Learning[EB/OL]. arXiv:2502.14768, 2025. <https://arxiv.org/abs/2502.14768>.
8. Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations. 2022. <https://arxiv.org/abs/2106.09685>.
9. Hugging Face. TRL GRPO Trainer Documentation[EB/OL]. https://huggingface.co/docs/trl/en/grpo_trainer.

10. Hugging Face. Open-R1: A Fully Open Reproduction of DeepSeek-R1[EB/OL]. GitHub, 2025. <https://github.com/huggingface/open-r1>.
11. nlile. 24-game Dataset[DB/OL]. Hugging Face. <https://huggingface.co/datasets/nlile/24-game>.
12. test-time-compute. Game-of-24 Dataset[DB/OL]. Hugging Face. <https://huggingface.co/datasets/test-time-compute/game-of-24>.
13. Pan J. Countdown-Tasks-3to4 Dataset[DB/OL]. Hugging Face. <https://huggingface.co/datasets/Jiayi-Pan/Countdown-Tasks-3to4>.

8 附录：复现命令与结果路径

8.1 主线实验

```
export PYTHONPATH=$PWD
export QWEN_15B=/path/to/Qwen2.5-1.5B-Instruct

export N_EVAL=200
export N_HARD=100
export BEST_OF=8
export GRPO_SAMPLES=300
export GRPO_GENERATIONS=8
bash scripts/run_15b_mainline.sh "$QWEN_15B" 0
```

8.2 Best-of-N Sweep

```
export N_EVAL=200
export N_HARD=100
export BEST_OF_LIST="1 4 8 16"
bash scripts/run_ttc_sweep.sh "$QWEN_15B" 0
```

8.3 Countdown 加分项

```
export COUNTDOWN_TRAIN=3000
export COUNTDOWN_EVAL=200
export BEST_OF=8
export GRPO_SAMPLES=300
export GRPO_GENERATIONS=8
bash scripts/run_countdown_bonus.sh "$QWEN_15B" 0
```

8.4 关键结果路径

内容	路径
1.5B base 评估	results/game24-15b-base/
1.5B SFT 评估与曲线	results/game24-sft-15b-curriculum/
1.5B SFT+GRPO 评估与曲线	results/game24-grpo-15b-curriculum/
GRPO 超参对照	results/game24-grpo-15b-lr3e-7-s300/, results/game24-grpo-15b-lr3e-7-s600/
Countdown 加分项	results/countdown-sft-15b/, results/countdown-grpo-15b/
报告图表	docs/report/figures/

早期 0.5B direct GRPO 和 3B 预实验保留在 `results/` 中作为探索过程归档。由于训练协议不同，它们不作为正式模型规模对照。